# 📘 ข้อกำหนดโครงงานรายวิชา (Term Project Guidelines)

วิชา: Introduction to Natural Language Processing

สัดส่วนคะแนน: 15% ของคะแนนทั้งหมด

หัวข้อ: ระบบวิเคราะห์เชิงลึกและการจำแนกข้อความแบบครบวงจร (End-to-End NLP Insight & Classification System)

## 🎯 วัตถุประสงค์

เพื่อให้นักศึกษาประยุกต์ใช้องค์ความรู้ตั้งแต่สัปดาห์ที่ 1 ถึง 14 ในการสร้าง Pipeline ทางภาษาที่สมบูรณ์ โดยต้องแสดงให้เห็นถึงความสามารถในการจัดการข้อมูลดิบ (Raw Text), การค้นหาโครงสร้างที่ซ่อนอยู่ (Unsupervised), และการเปรียบเทียบประสิทธิภาพระหว่างโมเดลทางสถิติแบบดั้งเดิมกับโมเดล Deep Learning สมัยใหม่

## 📋 รายละเอียดเนื้องาน (Requirements)

นักศึกษาต้องเลือก **Domain ของข้อมูล** ที่สนใจ (เช่น ข่าวการเมือง, รีวิวสินค้า E-commerce, บทคัดย่อทางการแพทย์ หรือ กระทู้ Webboard) และดำเนินการตาม 4 ระยะ (Phases) ดังนี้:

### 📌 Phase 1: Data Engineering (ครอบคลุม Week 2-4)

- **1.1 การรวบรวมข้อมูล (Data Collection):**
  - **Standard Dataset:** เลือกชุดข้อมูลมาตรฐาน 1 ชุดเพื่อเป็นฐาน (Baseline)
  - **Web Scraping (บังคับ):** ต้องเขียนโปรแกรม (ใช้ requests, BeautifulSoup ตามที่เรียนใน Week 3) เพื่อเก็บข้อมูลใหม่จากอินเทอร์เน็ต (ปี 2025-2026) จำนวนอย่างน้อย 500-1,000 รายการ เพื่อนำมาเพิ่มในชุดข้อมูล
- **1.2 การเตรียมข้อมูล (Preprocessing Pipeline):**
  - สร้าง Pipeline สำหรับทำความสะอาดข้อมูล: จัดการ HTML tags, URLs, Emojis
  - **Tokenization Comparison:** เปรียบเทียบผลลัพธ์การตัดคำระหว่างเครื่องมือ 2 แบบ (เช่น NLTK vs spaCy หรือ เปรียบเทียบ Word-level vs Subword-level)

## 📌 Phase 2: Unsupervised Discovery (ครอบคลุม Week 9-11)

- **2.1 การหาหัวข้อเรื่อง (Topic Modeling):**
  - ใช้เทคนิค **LDA (Latent Dirichlet Allocation)** หรือ **NMF** เพื่อค้นหา "Theme" หรือหัวข้อที่ซ่อนอยู่ในข้อมูลที่ Scrape มาใหม่ (กำหนด k=5 ถึง 10 หัวข้อ) และอภิปรายผลว่าหัวข้อที่ได้มีความหมาย (Interpretability) หรือไม่
- **2.2 การสกัดชื่อเฉพาะ (NER):**
  - ใช้ Pre-trained model (เช่น spaCy) เพื่อดึง Entity (เช่น ชื่อคน, องค์กร, สถานที่) ออกมา และทำสรุปสถิติเบื้องต้น (เช่น องค์กรใดถูกพูดถึงมากที่สุดในข้อมูลชุดนี้)

## 📌 Phase 3: The "Classic vs. Neural" Showdown (ครอบคลุม Week 6-8, 12-14)

นักศึกษาต้องเลือกโจทย์ **Text Classification** (เช่น Sentiment Analysis หรือ News Categorization) และแก้โจทย์ด้วย 2 วิธีการเพื่อเปรียบเทียบกัน:

- **วิธีที่ A: แนวทางคลาสสิก (The Classical Approach)**
  - **Feature:** ใช้ Bag-of-Words หรือ **TF-IDF**
  - **Model:** ใช้โมเดล Machine Learning มาตรฐาน เช่น Naive Bayes, Logistic Regression หรือ Random Forest
- **วิธีที่ B: แนวทาง Deep Learning (The Neural Approach)**
  - **Feature:** ใช้ **Word Embeddings** (Word2Vec หรือ GloVe) เป็น Input หรือใช้ **Doc2Vec**
  - **Model:** สร้างโมเดล Deep Learning โดยใช้สถาปัตยกรรม **RNN, LSTM หรือ GRU** (อนุญาตให้ใช้ PyTorch/TensorFlow/Keras)

## 📌 Phase 4: Evaluation & Application (ครอบคลุม Week 7, 13)

- **4.1 การวัดผล:** รายงานผลด้วยค่า Precision, Recall, และ F1-Score (ห้ามใช้ Accuracy เพียงอย่างเดียว)
- **4.2 Document Search (Bonus/Optional):** ลองนำเวกเตอร์จากวิธีที่ B (Embeddings) มาทำระบบค้นหาเอกสารอย่างง่ายด้วย **Cosine Similarity** เพื่อดูว่าเมื่อใส่ Query เข้าไป ระบบคืนค่าเอกสารที่เกี่ยวข้องได้ถูกต้องหรือไม่

### 📌 Phase 5: AI Audit Log (สำคัญมาก ❗)

เนื่องจากอนุญาตให้ใช้ AI (เช่น ChatGPT/Gemini) ช่วยเขียนโค้ด นักศึกษาต้องทำบันทึกการใช้งาน เพื่อพิสูจน์ว่า **"คุณเป็นคนตรวจสอบ AI ไม่ใช่ให้ AI ทำงานแทนทั้งหมด"**

## 📝 รูปแบบรายงาน AI Audit Log (ตัวอย่าง)

นักศึกษาต้องส่งตาราง Log ท้ายรายงาน โดยมีรายละเอียดดังนี้:

| Task | Prompt ที่ใช้ | ผลลัพธ์จาก AI (ย่อ) | การตรวจสอบและแก้ไข (Human Verification) |
|---|---|---|---|
| **Regex Cleaning** | "Write regex to remove email from text" | r'[a-zA-Z0-9]+@[a-zA-Z]+' | **Fail:** โค้ด AI ไม่ครอบคลุมอีเมลที่มีจุด (.)<br>**Fix:** แก้ไข Pattern เองเป็น r'[\w\.-]+@[\w\.-]+' |
| **Model Training** | "Build LSTM model with PyTorch" | (Code Snippet...) | **Pass w/ Edit:** โค้ดรันผ่านแต่ไม่รองรับ GPU<br>**Fix:** เพิ่มบรรทัด .to(device) เพื่อความเร็ว |
| **Scraping** | "Scrape news titles from XYZ.com" | soup.find('div', class_='title') | **Fail:** ชื่อ Class หน้าเว็บเปลี่ยนไปแล้ว<br>**Fix:** Inspect หน้าเว็บจริง แล้วแก้เป็น class_='news-header-v2' |

## 📊 เกณฑ์การให้คะแนน (Rubric) - 15%

| ส่วนประกอบ (Component) | รายละเอียดการพิจารณา | คะแนน (15) |
|---|---|---|
| **1. Data & Pipeline** | มีการทำ Web Scraping จริง, ข้อมูลมีคุณภาพ, เลือกใช้วิธี Preprocessing (Cleaning/Tokenization) ได้ถูกต้องตามหลักการ | **3** |
| **2. Discovery (Topic/NER)** | สามารถใช้ LDA/NMF หาหัวข้อเรื่องได้ และดึง Entity (NER) ออกมาวิเคราะห์ข้อมูลได้น่าสนใจ | **3** |
| **3. Model Implementation** | สร้างโมเดลได้ถูกต้องทั้ง 2 แบบ:<br>1. Classic (TF-IDF + ML)<br>2. Neural (Embeddings + RNN/LSTM) | **3** |
| **4. AI Audit & Evaluation & Analysis** | มี AI Audit Log ที่แสดงให้เห็นการ Debug/แก้ไขโค้ดจริง, การวัดผลถูกต้อง (F1, Precision, Recall), มีการวิเคราะห์ Error Analysis (วิเคราะห์ว่าทำไมโมเดลหนึ่งถึงชนะอีกโมเดลหนึ่ง), และเปรียบเทียบข้อดีข้อเสียของ Embeddings vs Bag-of-Words | **4** |
| **5. Presentation** | สไลด์นำเสนอเข้าใจง่าย, Code ใน Notebook รันได้จริงและมีการเขียนอธิบาย (Comment) ชัดเจน | **2** |

## 💡 คำแนะนำสำหรับนักศึกษา (Tips for Students)

- **ความเชื่อมโยง:** โปรเจกต์นี้ถูกออกแบบมาให้คุณเห็นภาพว่า "ทำไม" เราถึงต้องย้ายจาก TF-IDF ไปเป็น Word Embeddings และ Deep Learning ให้เน้นการอภิปรายผลเปรียบเทียบในส่วนนี้
- **เครื่องมือ:** สามารถใช้ Library ที่เรียนมาได้ทั้งหมด (NLTK, spaCy, scikit-learn, Gensim, PyTorch/TensorFlow)
- **ส่งงาน:** ส่งเป็น Jupyter Notebook (.ipynb) ที่รันผลลัพธ์ค้างไว้ พร้อมไฟล์ข้อมูล (Dataset) ที่ใช้ และไฟล์ Presentation